扫地僧 AI 量化平台 Qlib 给力教程系列一

核心篇

详细目录、知识点与安装错误处理

作者：扫地僧，微信：saodiseng2099，QQ 群 271879452

上课点击荔枝微课网址 https://m.lizhiweike.com/liveroom2/27759692
或微信扫描如下二维码上课

纸上得来终觉浅，绝知此事要躬行！

——陆游

1 视频课程网址: https://m.lizhiweike.com/channel2/1491650

2 答疑请到 QQ 群 271879452

4 课程详情见知乎专栏：https://www.zhihu.com/people/optmaster/columns

5 扫地僧微信 saodiseng2099，微信公众号 optMaster，

6 扫地僧量化学习官网： https://hkhappy.gitee.io/quantcn/

扫地僧AI量化平台Qlib给力教程系列一：核心篇

课程详细目录与知识点

目录

扫地僧AI量化平台Qlib给力教程系列一：核心篇 3
1. Qlib安装与数据准备 6
1.1. Qlib简介 6
1.2. 安装Qlib 6
1.3. 行情数据下载 7
1.4. 行情数据查询 7
2. 训练、预测与回测工作流 8
2.1. 初始化，设置股票池和基准 8
2.2. 训练 8
2.3. 预测 8
2.4. 回测 8
2.5. 其它功能 8
2.6. dataset数据查询与保存为pickle文件 8
2.7. 集成quantstats与pyfolio展示回测绩效 8
3. 从中间开始工作流，多步一个实验工作流 9
3.1. 利用pickle文件从中间开始工作流 9
3.2. 训练预测回测多步一个实验 9
4. 从yaml文件自动生成python配置字典，运行qlib所有模型例子实验 9
5. 不用实验管理器R的实验 9
5.1. 不用实验管理器R的实验过程 9
5.2. 利用模型和数据集pickle文件从中间开始实验 9
6. 数据集dataset与数据预处理详解 9
6.1. Alpha360的数据预处理核心逻辑 9
6.2. 推理处理器与学习处理器的区别 9
6.3. dataset.prepare()方法访问数据 9
6.4. Alpha360定义特征和标签的接口方法 9
6.5. 特征（因子）定义的原则：去单位化，即无量纲化 9

6.6. Alpha158的数据预处理 9
6.7. 定制数据预处理 10
6.8. 内置预处理器功能介绍 10
7. 自定义因子库类 10
7.1. 观察内置Alpha360因子库类 10
7.2. 自定义因子库类 10
7.3. 自定义因子库类可用的算子 10
7.4. 使用非字符串表达式定义特征 10
8. 回测策略解析 10
8.1. 引例 10
8.2. 总体逻辑 10
8.3. TopkDropoutStrategy和SimulatorExecutor源码分析 10
8.4. 另一个回测入口点 10
9. 使用其它机器学习模型（运行qlib所有模型例子实验，以及外部模型的封装） 10
9.1. 使用LSTM模型 10
9.2. 筛选出特定特征参与训练 10
9.3. 使用XGBoost模型 10
9.4. 转化为时间序列数据进行训练：_ts.py文件里的模型 10
9.5. 自定义模型封装类 10
10. qrun运行yaml文件配置的实验（直接通过yaml配置文件运行qlib自带所有模型实验） 10
10.1. qrun运行yaml实验配置文件，web页查看结果 11
10.2. cli.py文件 11
11. 使用自己的数据源准备qlib数据 11
11.1. Qlib使用的yahoo财经数据准备过程核心逻辑回顾 11
11.2. 从akshare生成原始未复权的行情csv 11
11.3. 生成复权csv 11
11.4. 生成Qlib格式的bin数据 12
11.5. 准备csv文件过程总结 12
11.6. dump_bin.py dump_update增补后续时段的新行情数据 12

11.7. dump_bin.py dump_fix 补充以往同时段内的新股票或新特征 12
11.8. 制作含外部特征的因子库类 MyAlphaExt 12
11.9. 更简单的数据准备过程 12
11.10. 生成最新股票池文件如 csi300.txt 等 12
12. 与 backtrader 结合 12
12.1. Qlib 执行训练预测 12
12.2. 获取预测值 score 12
12.3. 合并 ohlc 和 score 12
12.4. 数据喂给 backtrader 12
13. 一个第三方数据解决方案 13
14. 常见错误处理 13
14.1. 安装 qlib 时出错提示:error: Microsoft C++ 14.0 or greater is required 13
14.2. 检查 C 盘是否满了 14
14.3. 不要用 pip install pyqlib 安装 qlib 14
14.4. downloaddata.ipynb 下载出错 14
14.5. 运行 aksharecustomData 报错 module 'bson' has no attribute 'encode' 15
14.6. 生成 dataset 时出错：TypeError: connot do slice indexing 15
14.7. 执行实验程序，出现错误：NameError: name 'rolling_resi' is not defined 15

1. Qlib 安装与数据准备

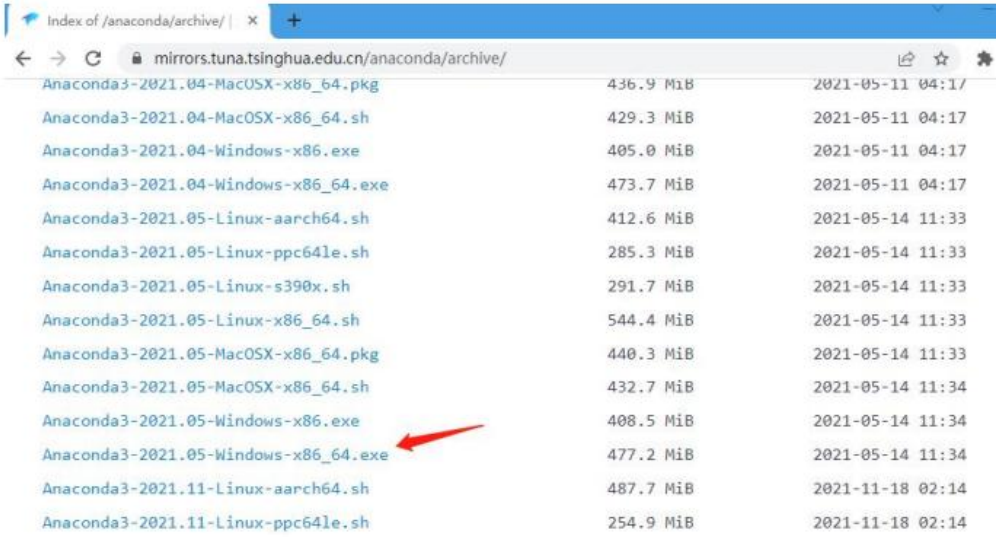
1.1. Qlib 简介

1.2. 安装 Qlib

1.2.1. 安装 Anaconda3-2021.05(内含 Python 3.8.8)

Anaconda3-2021.05-Windows-x86_64.exe 下载地址：

https://mirrors.tuna.tsinghua.edu.cn/anaconda/archive/



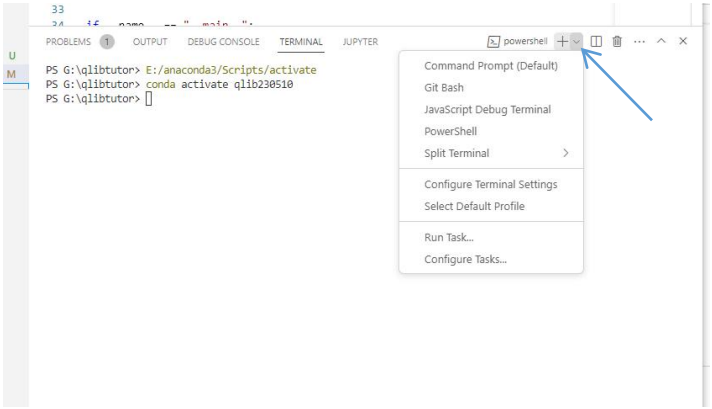
1.2.2. 安装 Qlib

为了保证和本视频教程操作过程的一致性，我们已将教程使用的 qlib 源码放到课程附件里，请用户直接下载它解压到本地，然后通过“pip install .”来安装。

以下是几个注意点：

（1）在 vscode 终端的命令提示符下安装

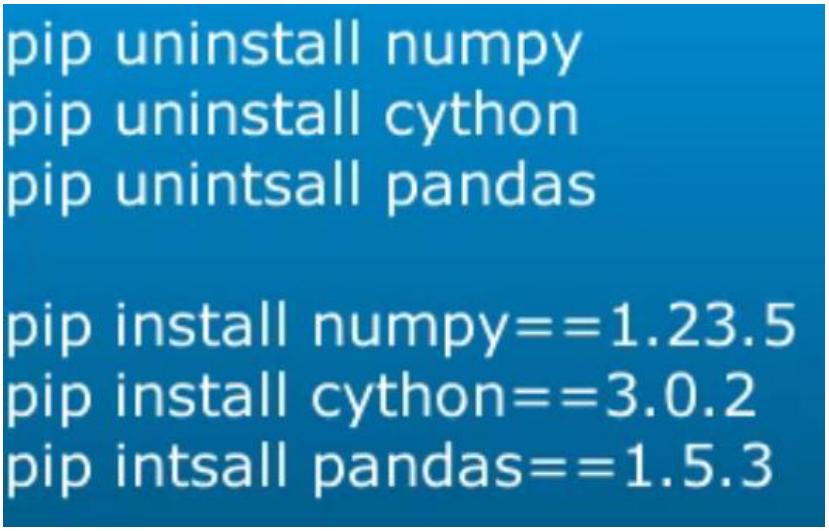
不要在 powershell 下安装，如果已经处于 vscode 的 powershell 下，则通过如下箭头处按钮选 Command Prompt。



（2）不要用 pip install pyqlib 来安装，因为它安装的版本可能与教程不一致，运行教程实验可能会出错。

（3）也不要用 python setup.py install 来安装，因为它无法覆盖已经安装的老版本，未来升级会有问题。参考 https://github.com/microsoft/qlib 页面下的安装说明。

1.2.3. 如下三个库安装到指定版本



1.2.4. 其他安装问题参考第 14 章

1.3. 行情数据下载

1.4. 行情数据查询

1.4.1. 定义基于文件的股票池（复权因子解释）

1.4.2. 定义派生字段

1.4.3. 使用算子

1.4.4. 检索股票池股票代码

1.4.5. 检索交易日历

1.4.6. 定义基于股票代码列表的股票池

1.4.7. 自定义文件股票池

1.4.8. D 数据接口方法

1.4.9. 股票池过滤

2. 训练、预测与回测工作流

2.1. 初始化，设置股票池和基准

2.2. 训练

2.2.1. 训练参数设置

2.2.2. 通过配置实例化模型和数据集对象

2.2.3. early_stopping_rounds，num_boost_round

2.3. 预测

2.3.1. 预测实验

2.3.2. 预测结果查询

2.3.3. 预测绩效分析图

2.3.4. 特征重要性

2.4. 回测

2.4.1. 回测实验

2.4.2. 回测结果查询

2.4.3. 回测绩效分析图

2.5. 其它功能

2.5.1. 实验记录管理器 R 和实验记录器的接口方法浏览

2.5.2. mlflow ui 查看 web 实验记录

2.5.3. 如何删除磁盘上的实验结果目录

2.6. dataset 数据查询与保存为 pickle 文件

2.6.1. 查看全部特征和标签数据

2.6.2. 查看标签（即预测对象）的定义

2.6.3. 查看特征的定义

2.6.4. dataset 保存为 pickle 文件

2.7. 集成 quantstats 与 pyfolio 展示回测绩效

参见 https://zhuanlan.zhihu.com/p/588946219

3. 从中间开始工作流，多步一个实验工作流

3.1. 利用 pickle 文件从中间开始工作流

3.1.1. 加载数据集 pickle 文件

3.1.2. 加载模型 pickle 文件

3.1.3. 执行回测

3.2. 训练预测回测多步一个实验

3.2.1. 创建 model 和 dataset

3.2.2. 训练预测回测在一个实验中完成。

3.2.3. 预测结果查询与分析

3.2.4. 回测结果查询与分析

3.2.5. mlflow ui 查看实验记录

4. 从 yaml 文件自动生成 python 配置字典，运行 qlib 所有模型例子实验

Qlib 内的 benchmarks 目录含有几十个模型实验相关的配置文件，只不过是 yaml 格式的，我们可以将其自动转换为 python 字典格式，这样就可以在 python 程序中直接运行 qlib 自带的几十个模型实验了。

5. 不用实验管理器 R 的实验

5.1. 不用实验管理器 R 的实验过程

5.2. 利用模型和数据集 pickle 文件从中间开始实验

6. 数据集 dataset 与数据预处理详解

6.1. Alpha360 的数据预处理核心逻辑

6.2. 推理处理器与学习处理器的区别

6.3. dataset.prepare()方法访问数据

6.3.1. 检索原始数据

6.3.2. 检索推理数据（用于预测）

6.3.3. 检索学习数据（用于训练与验证）

6.4. Alpha360 定义特征和标签的接口方法

6.5. 特征（因子）定义的原则：去单位化，即无量纲化

6.5.1. Alpha360 特征定义源码

6.6. Alpha158 的数据预处理

6.7. 定制数据预处理

6.8. 内置预处理器功能介绍

7. 自定义因子库类

7.1. 观察内置 Alpha360 因子库类

7.2. 自定义因子库类

7.3. 自定义因子库类可用的算子

7.4. 使用非字符串表达式定义特征

8. 回测策略解析

8.1. 引例

8.2. 总体逻辑

8.3. TopkDropoutStrategy 和 SimulatorExecutor 源码分析

8.4. 另一个回测入口点

9. 使用其它机器学习模型（运行 qlib 所有模型例子实验，以及外部模型的封装）

本节介绍怎样根据 qlib 内置的几十个模型 yaml 格式的实验配置文件，手工转为 python 配置字典，执行实验，可以和前面第 5 章的方法进行比较，两种方法可以。也介绍怎样封装 qlib 没有的机器学习模型。

9.1. 使用 LSTM 模型

9.1.1. Qlib 内置模型浏览

9.1.2. 安装 pyTorch

9.1.3. LSTM 模型配置

9.1.4. data_handler_config 设置

9.2. 筛选出特定特征参与训练

9.3. 使用 XGBoost 模型

9.4. 转化为时间序列数据进行训练：_ts.py 文件里的模型

9.4.1. TSDatasetH 与 step_len

9.4.2. 带_ts 后缀的模型文件

9.5. 自定义模型封装类

9.5.1. 继承 Model,FeatureInt（可选）

9.5.2. 实现接口__init__，fit，predict，get_feature_importance（可选）

10. qrun 运行 yaml 文件配置的实验(直接通过 yaml 配置文件运行 qlib 自带所有模型实验）

10.1. qrun 运行 yaml 实验配置文件，web 页查看结果

10.2. cli.py 文件

11. 使用自己的数据源准备 qlib 数据

11.1. Qlib 使用的 yahoo 财经数据准备过程核心逻辑回顾

参考 scripts\data_collector\yahoo\collector.py

11.1.1. 下载原始 csv

从 yahoo 财经下载 csv 文件，含字段 date open high low close volume adjclose，其中 ohlc 是原始价格，adjclose 是复权收盘价。

11.1.2. 生成复权数据

生成复权因子 factor = adjclose/close，然后利用 factor 生成 ohlc 的复权价格（比如复权 open=原始 open*factor），以及复权成交量(复权 volume=原始 volume/factor)

11.1.3. 用最早的收盘价_close 标准化数据 csv

即 ohlc 和 factor 等除以_close，标准化数据，生成标准 csv。

根据 Qlib 开发者的说法，第 3 步标准化有助于训练。但是我们发现，如果做这个处理，在后续要增加数据时，会很麻烦，因为每次增加数据，都要取得增加前最早的收盘价来标准化，而不是用新增数据自己的第一个收盘价做标准化。我们觉得实际没必要做第 3 步标准化处理，因为未来生成因子库类（如 Alpha158）时，会做无量纲化处理，已经能够满足模型训练的要求了。

所以，以下我们采用 akshare 的数据来准备 qlib 的数据时，不做第 3 步，只做第 1、2 两步。

11.2. 从 akshare 生成原始未复权的行情 csv

从 akshare 下载行情数据，生成原始 csv 文件。

Csv 含字段'date','open','close', 'high', 'low', 'volume', 'amount', 'turnover' 'symbol'，不含索引。

11.3. 生成复权 csv

11.3.1. 异常数据处理

设置 date 为索引，去重复日期，处理异常成交量，异常价格（变化过大）。

AkshareNormalize 类的方法 normalize_akshare 做。

AkshareNormalize 类的 COLUMNS = ["open", "close", "high", "low",

"volume"] 设置需要复权的字段。

11.3.2. 生成复权数据

生成复权价格、复权成交量、复权流通股数和复权因子 factor。

factor=adjclose/close,然后利用 factor 生成 ohlc 的复权价格

（比如复权 open=原始 open*factor），

以及复权成交量(复权 volume=原始 volume/factor)。

注意这里我们没有用 akshare 直接提供的复权因子，

而是自己用 adjclose/close 计算复权因子。

AkshareNormalize1d 类的方法 adjusted_price 做。

11.4. 生成 Qlib 格式的 bin 数据

交易日历 day.txt 自动生成，取所有 csv 文件的日期合集，

制作股票池文件

11.5. 准备 csv 文件过程总结

复权处理代码讲解。

11.6. dump_bin.py dump_update 增补后续时段的新行情数据

此步要先把原来的 csv 文件全部删除，再执行，否则有可能出错。

11.7. dump_bin.py dump_fix 补充以往同时段内的新股票或新特征

此步**必须**先把原来的 csv 文件全部删除，再执行，否则有可能出错。

11.8. 制作含外部特征的因子库类 MyAlphaExt

行情数据中的 turnover 作为特征

11.9. 更简单的数据准备过程

11.10. 生成最新股票池文件如 csi300.txt 等

G:\qlibtutor\scripts\data_collector\cn_index\collector.py

可能有错误，待修正

12. 与 backtrader 结合

12.1. Qlib 执行训练预测

12.2. 获取预测值 score

12.3. 合并 ohlc 和 score

12.4. 数据喂给 backtrader

13. 一个第三方数据解决方案

Qlib 数据准备工作涉及数据质量校验、数据持续更新等一系列问题，处理比较繁琐。为解决这些问题，有个热心开发者专门开发了一个 A 股数据集，是 qlib 直接可用的 bin 格式，该数据集每天自动更新，用户只要下载该数据集复制到 qlib 数据目录下即可使用，方便了数据准备工作。该数据集还包含北交所数据。数据集下载地址是 https://github.com/chenditc/investment_data/releases 用户只需下载 qlib_bin.tar.gz 压缩文件即可，里头是 qlib bin 格式数据文件。

这个数据集是如何生成和维护的，可以参考这个热心开发者的博客文章，在这里。

14. 常见错误处理

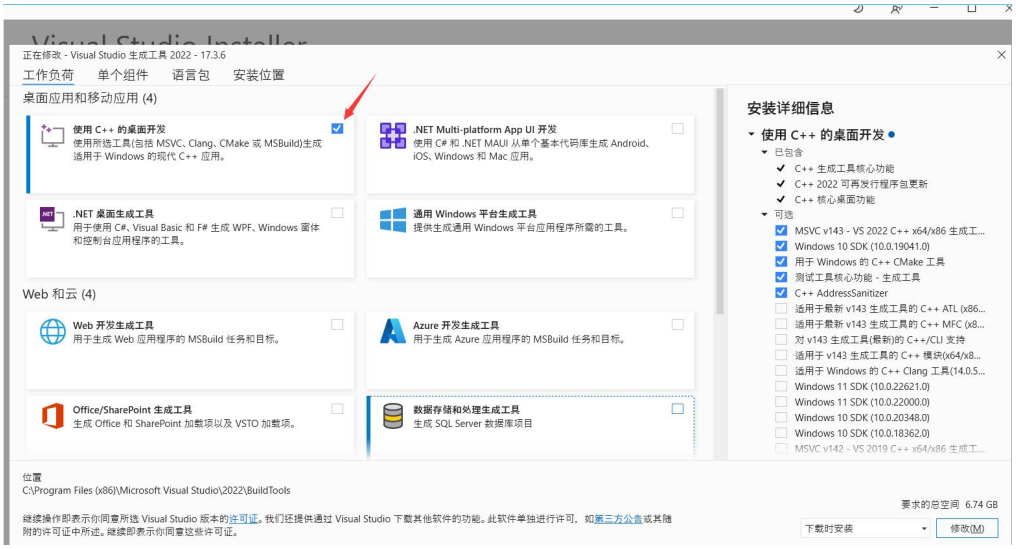
14.1. 安装 qlib 时出错提示:error: Microsoft C++ 14.0 or greater is required

解决办法：可去网址 https://visualstudio.microsoft.com/zh-hans/visual-cpp-build-tools/

下载生成工具，如下图：



下载好后安装时选择如下选项，进行安装，完成后重启系统即可。



14.2. 检查 C 盘是否满了

特别是安装 C++build 工具前 C 盘空间是否足够，安装后 C 盘是否满了。若满了很可能会出错。

14.3. 不要用 pip install pyqlib 安装 qlib

这样安装的版本可能与视频教程不一致，导致实验出错。要用我视频里的方法安装。

14.4. downloaddata.ipynb 下载出错

出错信息：由于 Win32api 模块出错，kernel 启动失败。请考虑(重新)安装此模块。有关详细信息，请单击。出错截图如下：



解决办法 1：

pip uninstall pywin32

pip install pywin32==225

解决办法 2：

不下载数据，直接复制课程附件的数据到对应目录。

14.5. 运行 aksharecustomData 报错 module 'bson' has no attribute 'encode'

解决：pip uninstall bson， pip uninstall pymongo，pip install pymongo

14.6. 生成 dataset 时出错：TypeError: connot do slice indexing

```
TypeError: cannot do slice indexing on Index with these indexers [1892] of type int
```

解决：pip install pandas==1.5.3

14.7. 执行实验程序，出现错误：NameError: name 'rolling_resi' is not defined

这是因为 pyx 文件没编译。重新按视频安装 qlib 即可。

附录 以下列出扫地僧量化系列课程

我们开发的 Backtrader 技术教程资料如下：

1 《扫地僧 Backtrader 给力教程系列一：量化回测核心篇 增订版》

2 《扫地僧 Backtrader 给力教程系列二：量化回测与实盘交易高级篇》

** 单独购买纸版教程淘宝：https://shop596279012.taobao.com

** 若购买视频课程，则免费赠送纸版教程，地址：https://m.cctalk.com/inst/stsbbxhz

2 《扫地僧 Backtrader 给力教程系列二：量化回测与实盘交易高级篇》

** 单独购买纸版教程（实盘接口为加密版）淘宝：https://shop596279012.taobao.com/

** 购买视频课程，则赠送纸版教程和实盘接口源码（非加密版），地址：https://m.cctalk.com/inst/stsbbxhz

** 请去 qq 群 271879452 下载“扫地僧 Backtrader 系列二_免费样书与源码.zip”，运行案例文件测试通过再下单。

3 《扫地僧 AI 量化平台 Qlib 给力教程系列一：核心篇》

cctalk 课堂购买链接 https://m.cctalk.com/inst/stsbbxhz

4 以上课程的免费样书和部分源码请到 QQ 群 271879452 下载，查阅样书目录即可了解教程详细内容，运行源码获取直接体验。

5 以上课程详情参见知乎专栏：https://www.zhihu.com/people/optmaster/columns

6 扫地僧微信 qtbhappy ，微信公众号 optMaster，

扫地僧量化官网 https://hkhappy.gitee.io/quantcn/